2025 글로벌 저작권 현안 신속 대응

공유저작물 속성 정보 기반 권리유형 자동 분류 AI (기능요구사항 정의서)

2025. 07. 30.

한국콘텐츠진흥원

2025 글로벌 저작권 현안 신속 대응

기능요구사항 정의서

2025. 07. 30.

연구수행자	에이치엠컴퍼니(주)

개정이력

Version	개정내용	개정일자	작성자	승인자
1.0	최초 작성	2025.06.24	박경재	박명찬

목 차

제 1 장 서론 ····· 1

1. 연구 배경 ····· 1

2. 연구의 목적 ····· 2

3. 개발 범위 ····· 2

제 2 장 시스템 개요 ····· 4

1. 시스템 구성 ····· 4

2. 시스템 아키텍처 ····· 6

3. 데이터 흐름 (Data Flow) ····· 6

4. 운영 환경 (Operational Environment) ····· 7

5. 표준 산출물(예시) ····· 7

6. 기대 효과 (Expected Effectiveness) ····· 7

제 3 장 기능요구사항 ····· 8

1. 기능 요구사항 정의 ····· 8

2. 기능별 상세 ····· 8

제 4 장 활용 방안 ····· 16

1. 활용 시나리오 ····· 16

2. 이미지 저작물 등록 ····· 16

3. 어문(텍스트) 저작물 등록 ····· 18

4. 영상 저작물 등록 ····· 20

5. 오디오 저작물 등록 ····· 22

6. 시나리오 C: 계약서 기반 ····· 24

제 5 장 성능 평가 및 검증 기준 ····· 26

1. 개요 ····· 26

2. 평가 지표 정의 ····· 26

3. 데이터셋 및 정답지 ····· 27

4. 평가 절차 ····· 27

5. 유형별 정확도 및 오류율 측정 ····· 28

6. 보고 형식 ····· 28

7. 수용 기준 ····· 28

제 6 장 결론 ····· 29

제1장 서론

1. 연구 배경

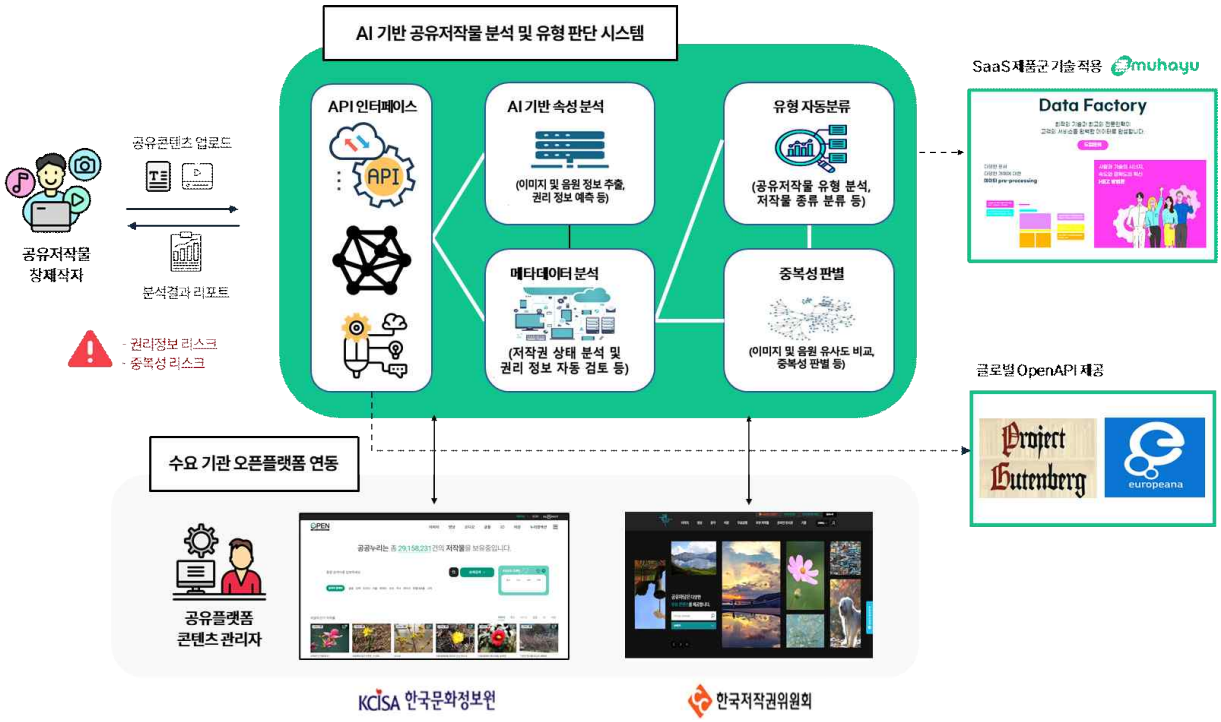

(그림 1) AI 기반 공유저작물 분석 및 유형 판단 시스템 개요도

디지털 환경에서 저작물의 생산과 유통은 과거 어느 때보다도 빠른 속도로 증가하고 있다. 음악, 영상, 이미지, 문서 등 다양한 형태의 디지털 콘텐츠가 공유되고 있으나, 이와 함께 저작권 침해 사례 또한 꾸준히 발생하고 있다. 특히 공공 영역에서 활용되는 공유저작물의 경우, 권리유형이 불명확하거나 메타데이터가 불완전한 상태로 제공되는 경우, 법적 분쟁이나 활용 제약으로 이어질 가능성이 크다. 이러한 문제는 공공저작물의 활성화를 저해하는 요인으로 작용하며, 권리 정보의 명확화와 체계적인 관리가 필요하다.

본 연구는 이러한 문제를 해결하기 위해 AI 기반 공유저작물 분석 및 유형 판단 시스템을 제안한다. 해당 시스템은 공유저작물이 업로드되면 자동으로 속성을 분석하고, 메타데이터를 추출하여 권리유형을 판정하는 기능을 수행한다. 특히 AI 기반 속성 분석 모듈은 텍스트, 이미지, 오디오 등 다양한 유형의 데이터를 처리하며, 얼굴 인식이나 로고 탐지 등을 통해 초상권 침해 가능성까지 검토할 수 있다. 이를 통해 관리자는 단순 수작업 검증에 의존하지 않고, 신뢰도 높은 자동화된 분석 결과를 제공받을 수 있다.

2. 연구의 목적

본 연구의 목적은 공유저작물의 속성 정보를 기반으로 권리유형을 자동으로 분류하는 AI 기술을 개발하고, 이를 실증하여 상용화를 위한 기반을 마련하는 데 있다.

2.1 공유저작물 메타데이터 및 속성 정보 자동 추출

공유저작물에 포함된 메타데이터 및 콘텐츠 속성 정보를 자동으로 추출하고, 이를 기반으로 KOGL, CC-BY 등 권리유형을 정확하게 판정하는 AI 모델을 개발한다. 이를 통해 관리자의 수작업 검증 부담을 줄이고, 공공저작물 활용 과정에서 발생할 수 있는 법적·관리적 리스크를 최소화한다.

2.2 AI 기반 속성 분석을 통한 권리 침해 가능성 판정

AI 기반 속성 분석과 초상권 판단 기능을 통합함으로써 텍스트, 이미지, 오디오 등 다양한 유형의 공유저작물에 대해 체계적이고 신뢰도 높은 판정을 수행한다. 특히 얼굴 탐지 및 로고 분석과 같은 기능을 포함하여 권리 침해 가능성을 보수적으로 판정함으로써 안전성을 확보한다.

2.3 공유저작물 중복 검증과 권리 충돌 탐지

국내 공유저작물 관리 플랫폼과 연계를 통해 중복 검증과 권리 충돌 탐지 기능을 강화한다. 이를 통해 공공저작물이 안정적으로 활용될 수 있는 기반을 마련한다.

3. 개발 범위

3.1 업로드 및 자동 분석 범위

시스템은 단건 업로드와 배치 업로드를 모두 지원할 수 있도록 설계 한다. 단건 업로드는 사용자가 UI를 통해 파일을 즉시 등록하여 실시간 분석을 수행하고, 배치 업로드는 예약/연계 경로를 통해 대량 파일을 수집하여 순차 또는 병렬로 처리한다. 업로드된 저작물에 대해 속성 자동 추출을 수행한다. 속성 자동 추출은 공동참여기관(숭실대학교)가 개발한 모듈을 통합하여 운용한다.

텍스트 문서는 내장 텍스트 추출 및 OCR을 통해 본문과 메타데이터를 확보하고, 이미지는 얼굴·로고·워터마크 등 주요 객체를 검출한다. 오디오/영상은 STT(Speech-to-Text)와 키워드/언어 식별을 통해 언어적 속성을 도출한다. 추출된 속성과 메타데이터를 입력으로 권리유형 자동 추정을 수행한다. 결과는 라벨과 신뢰도로 산출되어 후속 검토 단계에 전달된다. 이미지·영상의 얼굴 검출 결과는 보수적 임계치를 적용하여 초상권 보수 플래그를 부여한다. 임계치 이상일 경우 "검토 필요" 상태로 표기하여 관리자 검토 흐름으로 연계한다.

공유저작물 권리 판정은 계약서 기반 판정(우선)을 원칙으로 하며, 계약서가 없거나 판독 불가한 경우에는 유형 자동 추정 결과를 "검토 필요"로 분기한다. 기관 자체 제작물의 경우, 별도 계약서가 없어, 자유롭게 등록할 수 있다. 단, 초상권에 대해서는 별도 동의서 등이 있는 경우에만 적용한다.

3.2 표준 산출물

자동 판정 결과와 근거를 확인하고 검토·승인을 수행한다. 승인 전 라벨 수정, 반려, 재분석 요청을 지원하며, 모든 결정을 감사 가능하도록 기록한다.

표준 산출물은 다음과 같다.

- ✓ classification.json: 권리유형 라벨, 근거 키(메타·검출·텍스트)
- ✓ portrait.json: (이미지/영상) 얼굴 검출, 최종 결정(검토 필요/비해당), 적용 임계치
- ✓ transcript.json: (오디오/영상) STT 결과, 언어, 키워드/개체 정보
- ✓ keyframes: (영상) 키프레임 검출, 오버레이 이미지(시각적 근거)

제2장 시스템 개요

1. 시스템 구성

본 연구에서 제안하는 AI 기반 공유저작물 권리유형 자동 분류 시스템은 크게 4단계로 구성한다.

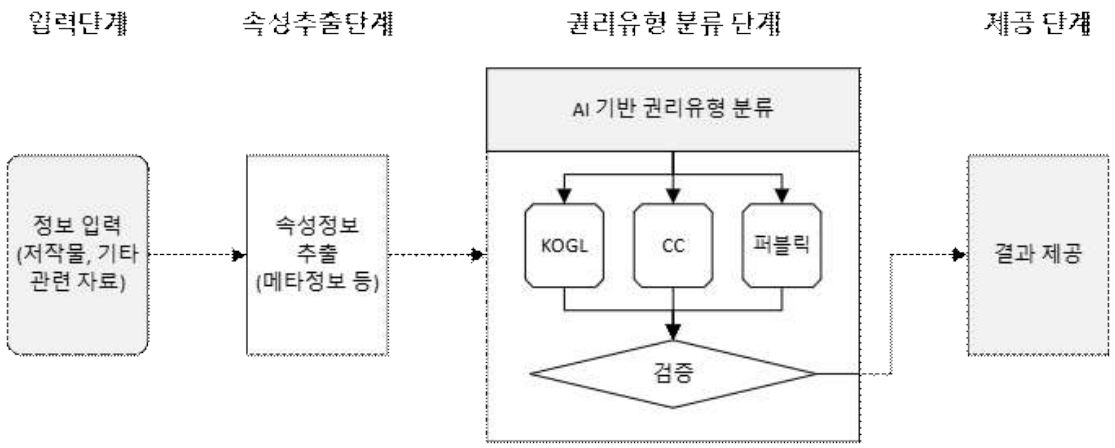

(그림 2) AI 기반 공유저작물 권리유형 자동 분류(추정) 시스템 구성도

1.1 입력 단계(Data Input)

입력 단계에서는 공유저작물의 원천 데이터를 시스템에 입력한다. 대상은 텍스트, 이미지, 오디오, 영상 등 다양한 형태의 저작물이며, 사용자가 직접 파일을 업로드 하거나 수요 기관 플랫폼과의 자동 연계를 통해 수집한다. 이 과정에서 파일명, 제작자, 등록일, 확장자 등 기본적인 메타데이터가 함께 확보되어 이후 분석 과정의 기초 데이터로 활용한다.

- ✓ 사용자가 파일을 업로드하거나, 수요 기관 플랫폼에서 자동 연계
- ✓ 기본 메타데이터(파일명, 제작자, 등록일, 확장자 등) 수집

1.2 속성 추출 단계(Feature Extraction)

입력된 저작물은 유형에 따라 속성 정보를 자동으로 추출한다. 텍스트 콘텐츠는 내장 텍스트와 관련 메타데이터를 수집하고, 이미지 콘텐츠는 얼굴·로고·워터마크와 같은 주요 객체를 검출한다. 오디오 및 영상 콘텐츠는 음성인식(STT)을 통해 텍스트로 변환하며, 주요 키워드와 화자 정보를 확보한다. 또한 모든 유형의 콘텐츠에 대해 파일 크기, 포맷, 생성일 등 공통 속성을 함께 수집한다.

- ✓ 텍스트 콘텐츠: 내장 텍스트 및 메타데이터 추출
- ✓ 이미지 콘텐츠: 얼굴, 로고, 워터마크 등 객체 검출
- ✓ 오디오/영상 콘텐츠: STT(Speech-to-Text), 주요 키워드 및 화자 정보 추출
- ✓ 공통 처리: 파일 크기, 포맷, 생성일 등 일반 속성 수집

1.3 AI 기반 권리유형 분류 단계(AI Classification)

이 단계에서는 추출된 속성 정보를 입력으로 받아 AI 모델이 권리유형을 자동으로 분류한다. KOGL 1~4 유형, CC-BY, CC-BY-SA, 퍼블릭도메인 등 주요 권리 체계를 대상으로 저작물의 권리적 지위를 명확히 판정한다. 얼굴 인식 결과에서 일정 확률 이상으로 얼굴이 포함된 경우에는 '검토 필요'로 분류하여 보수적인 초상권 판정을 수행한다. 또한 기존 공유저작물 데이터베이스와 비교하여 중복 여부를 검증하고, 유사도 분석을 수행한다. 또한, 분류된 결과는 국내외 플랫폼과 연계하여 검증한다. 국내에서는 한국문화정보원, 한국저작권위원회 시스템과 연동해 중복 여부 및 권리 충돌 가능성을 확인하고, 결과의 신뢰성과 활용성을 강화한다.

- ✓ 권리유형 추정: KOGL 1~4 유형, CC-BY, CC-BY-SA, 퍼블릭도메인 등
- ✓ 보수적 초상권 판정: 얼굴이 일정 확률 이상 포함되면 "검토 필요"로 표시
- ✓ 유사도 분석: 기존 등록된 공유저작물 DB와 비교하여 중복 여부 확인

1.4 계약서 처리 모듈(Contract Processor)

계약서 PDF/이미지 입력을 수신하고 비틀림/회전 교정(de-skew/de-rotate) 후 OCR을 수행한다. 직인/간인 등 스탬프 영역을 식별해 스캐닝 품질을 추정하고, 저작권 관련 핵심 조항(소유/저작재산권 양도·이용허락, 2차적 저작물, 범위/기간/지역, 납품물의 권리 귀속, 업무상 저작물)을 조항 추출기로 식별한다. 추출 결과는 contract_evidence.json에 기록되며, 계약서와 저작물 간 링킹(작업/발주번호, 납품물 식별자)을 강제한다.

1.5 결과 제공 단계(Output)

최종적으로 분석 결과를 관리자와 사용자에게 제공한다. 권리유형 코드(예: KOGL 제1유형), 초상권·저작권 리스크 여부, 중복 검증 결과와 근거 데이터 등을 종합 리포트로 제시한다. 관리자는 대시보드를 통해 자동 판정(추정) 결과를 확인하고 수작업 검증을 병행하며, 오류나 예외 상황이 발생하면 시스템이 즉시 경고 메시지를 전달해 신속히 대응할 수 있도록 한다.

2. 시스템 아키텍처

본 시스템은 모듈화된 아키텍처를 기반으로 설계하며, 각 단계가 독립적으로 동작하면서도 API를 통해 긴밀하게 연동한다.

- ✓ 입력 모듈은 사용자가 업로드한 파일과 수요기관 플랫폼에서 연계된 저작물을 수집한다.
- ✓ 속성 추출 모듈은 입력 데이터를 유형별로 분류하여 텍스트, 이미지, 오디오/영상 속성을 자동 분석한다.
- ✓ AI 분류 엔진은 추출된 속성을 기반으로 권리유형을 판정하고, 초상권 여부 및 중복 여부를 추가로 분석한다.
- ✓ 검증·연계 모듈은 국내외 플랫폼과 API로 연결되어 분석 결과의 신뢰성을 높인다.
- ✓ 결과 제공 모듈은 관리자 대시보드와 사용자 리포트를 통해 판정 결과를 제공한다.

이와 같은 계층형 구조는 모듈 간 결합도를 낮추고, 특정 기능(예: AI 모델, 속성 추출 알고리즘)을 교체하거나 확장하기 용이하다. 또한 클라우드 환경과 온프레미스 환경 모두에서 구동 가능하도록 설계하여 확장성과 유연성을 확보한다.

3. 데이터 흐름 (Data Flow)

시스템 내 데이터 흐름은 다음과 같다.

- ✓ 데이터 입력: 사용자가 파일을 업로드하거나 기관 플랫폼에서 자동으로 가져온다.
- ✓ 계약서 입력/링킹: 계약서 PDF/이미지 수신 → 파일 해시·발주번호·업체명으로 저작물과 연결
- ✓ 속성 추출: 파일 유형별로 메타데이터, 텍스트, 이미지 객체, 음성 텍스트 등이 추출된다.
- ✓ OCR·조항 추출: de-skew/de-rotate→OCR→저작권 핵심 문구 매칭/NER→contract_evidence.json
- ✓ 정책 판정: 계약 조항이 충분하면 계약 기반 판정이 AI 추정보다 우선한다. 미존재/불충분 시 검토 필요로 분기(기관 자체 제작물은 예외).
- ✓ AI 분석: 속성정보가 AI 모델로 전달되어 권리유형 분류 및 초상권/중복 여부 판정이 수행된다.
- ✓ 검증 및 연계: 분석 결과는 DB에 저장되며, 동시에 국내외 검증 플랫폼과 교차 검증한다.
- ✓ 결과 제공: 최종 결과는 관리자 대시보드와 사용자 리포트로 전달된다.

또한 시스템은 로그 데이터와 이력 데이터를 별도로 관리한다. 각 단계의 입력·출력 정보는 이력 DB에 기록되어, 추후 오류 분석과 학습 데이터 보강에 활용된다.

4. 운영 환경 (Operational Environment)

본 연구에서 제안하는 시스템은 연구 단계에서 실증 가능한 환경을 우선 구축하고, 이후 상용화를 고려한 확장성을 반영한다.

4.1 하드웨어 환경

- ✓ 서버: 20 Core CPU, DDR5 128GB RAM, GPU(NVIDIA RTX 5090 이상)
- ✓ 스토리지: 4TB 이상
- ✓ 네트워크: 100Mbps 이상 회선

4.2 소프트웨어 환경

- ✓ 네트분석 엔진: Python 기반 AI 모델 (PyTorch, TensorFlow 등 활용)
- ✓ 관리자 UI: 대시보드 형태(가능하면 수요처 UI 활용, 개발 시 단순 UI 형태)
- ✓ 데이터베이스: MariaDB 또는 PostgreSQL
- ✓ 연계 API: RESTful 구조, JSON 기반 데이터 교환

4.3 보안 요소

- ✓ 데이터 전송 시 SSL/TLS 암호화 적용
- ✓ DB 암호화 및 정기적 보안 점검 수행

5. 표준 산출물(예시)

- ✓ 이미지: classification.json, portrait.json
- ✓ 영상: classification.json, portrait.json, transcript.json, keyframes
- ✓ 오디오: classification.json, transcript.json, audio_fingerprint.json
- ✓ 어문: classification.json, evidence.json,

6. 기대 효과 (Expected Effectiveness)

본 시스템을 도입함으로써 다음과 같은 효과를 기대한다.

- ✓ 업무 효율성 향상: 자동화된 속성 추출과 권리 판정을 통해 기존 수작업 검증 업무 대폭 감소
- ✓ 저작권 리스크 최소화: 초상권 여부 및 중복 여부를 보수적 판정으로 법적 분쟁 가능성 예방
- ✓ 활용도 제고: 국내외 공유저작물의 활용 기반 강화
- ✓ 상용화 가능성 확보: 표준화·상용화 가능한 구조를 마련하여 공공·민간 영역으로 확산

제3장 기능요구사항

1. 기능 요구사항 정의

본 시스템의 기능 요구사항은 공유저작물의 권리유형을 정확하고 신뢰성 있게 판정하기 위해 네 가지 핵심 기능으로 정의한다.

항목	기능명	설명	입력	출력	비고
FR-01	**속성정보 수집**	계약서 파일 수신 및 저작물과 매핑	계약서 PDF/이미지, 메타(발주번호 등)	링크 토큰, 무결성 해시	필수
FR-02	**OCR 전처리**	de-skew/de-rotate, 품질 추정	계약서 원본	ocr_text.txt, 품질 점수	필수
FR-03	**저작권 조항 추출**	소유/양도/라이선스 조항 식별	ocr_text, 메타	contract_evidence.json	템플릿+NER
FR-04	**계약 우선 판정**	계약 조항 기반 권리 판정(우선 적용)	evidence, 정책	own/assign/license 등	정책 엔진
FR-05	**AI 기반 분류**	속성 기반 권리유형 분류 모델	속성정보	권리유형 코드	정확도 90%
FR-06	**초상권 여부 판단**	이미지 내 얼굴 여부 판단	이미지	초상권 여부	보수적 판단
FR-07	**예외 처리**	계약 없음/불충분/구업체 케이스 분기	상태 코드	검토 필요/보류	사유 기록
FR-08	**자체 제작**	기관 자체 제작 플래그 시 계약 없이 진행	플래그, 메타	정책 라벨	감사 로그

[표 4] 기능요구사항 정의

2. 기능별 상세

2.1 FR-01(속성정보 수집)

① 목적: 계약서 파일을 수신하고 저작물과 정확히 매핑하여 이후 OCR·조항 추출·정책 판정의 근거 마련

② 범위/대상: 텍스트, 이미지, 오디오, 영상 파일 전 종류. 업로드(수동) 및 기관 플랫폼 연계(자동) 포함

③ 입력/출력 스키마

- ✓ 입력: 업로드 파일(저작물 + 계약서 등) + 입력폼 메타데이터(JSON)
- ✓ 출력: 표준화 속성(JSON) 예시

```
{
  "fileId": "uuid",
  "fileName": "name.ext",
  "mediaType": "image|text|audio|video",
  "sizeBytes": 123456,
  "hash": "sha256:...",
  "creator": "string|null",
  "createdAt": "2025-08-24T04:00:00Z",
  "ingestedAt": "2025-08-24T04:05:00Z",
  "textProps": { "charCount": 1024, "language": "ko", "keywords": ["..."] },
  "imageProps": { "width": 1920, "height": 1080, "format": "png" },
  "audioVideoProps": { "durationSec": 37.2, "codec": "aac", "transcriptStub": true },
  "common": { "source": "upload|api", "platformRef": "ext-id-or-null"
}
```

(그림 3) 입/출력 스키마(예시)

④ 처리 로직(요약)

파일 무결성/바이러스 검사 → MIME/확장자 식별 → 기본 메타데이터 추출 → 유형별 속성(텍스트/이미지/STT 등)추출 → 표준 JSON 변환 → 속성 DB 저장.

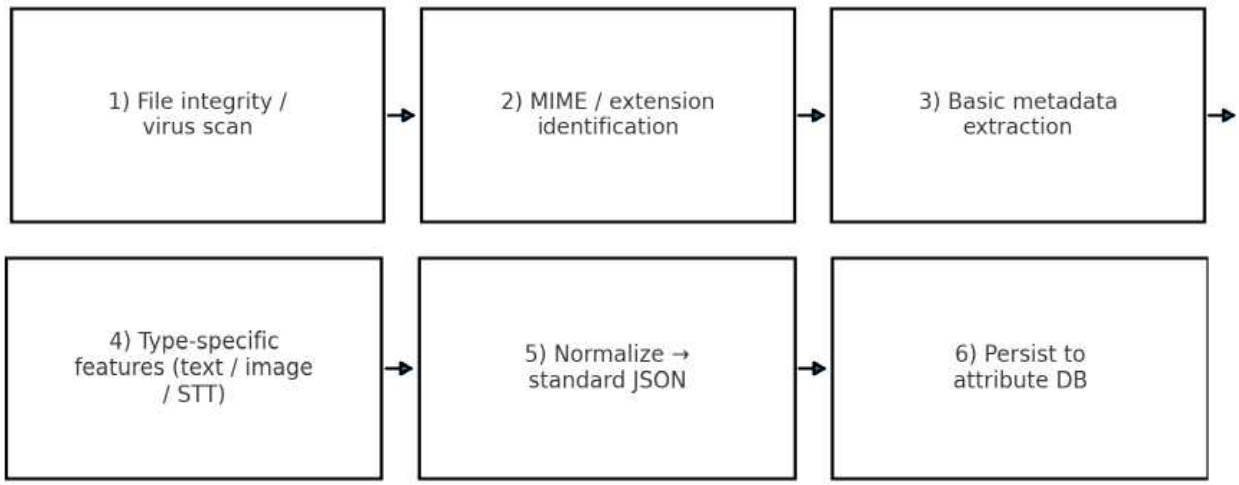

(그림 4) 처리 로직

⑤ 인터페이스

- ✓ API: POST /contracts(업로드), POST /contracts/{id}/link(파일 매핑).
- ✓ UI: 업로드 위자드(파일 선택, 메타데이터 입력, 진행률 표시)

⑥ 예외/오류 처리

✓ 손상 파일/미지원 코덱: 422 UNPROCESSABLE_ENTITY로 응답하고 사유 기록한다.

✓ 메타데이터 누락: 허용하되 누락 필드 표시 플래그(missingFields)를 추가한다.

✓ 대용량 파일: 스트리밍/청크 업로드로 전환한다.

⑦ 로그/감사: 업로더, 해시, 링크 키, 원본 경로, 매핑 결과 전부 기록한다.

2.2 FR-02(OCR 전처리)

① 목적: 스캔/사진 계약서의 기울기·회전·노이즈를 보정하고 고품질 OCR 텍스트를 생성한다.

② 범위/대상: de-skew/de-rotate, 해상도·품질 추정, 페이지 단위 처리한다.

③ 입력/출력 스키마

✓ 입력: 계약서 원본

✓ 출력: 분류 결과(JSON)

```
{
  "contractId":"uuid",
  "pages":[
    {"page":1,"angle":-3.2,"deskewed":true,"ocrConfidence":0.86},
    {"page":2,"angle":90,"autoRotate":true,"ocrConfidence":0.83}
  ],
  "wer":0.18,
  "timestamp":"2025-07-24T04:08:00Z"
}
```

(그림 5) 입/출력 스키마(예시)

④ 처리 로직(요약)

de-skew/de-rotate → OCR → 페이지별 신뢰도/해상도 수집 → 품질 점수 산출.

⑤ 인터페이스

✓ API: POST /contracts/{id}/ocr

⑥ 예외/오류 처리

✓ 판독 난이도 높음(저해상도/강압축) → "품질 저하" 플래그와 함께 검토 큐

⑦ 로그/감사: 각 페이지 처리시간, 각도, 신뢰도, 실패 사유

2.3 FR-03(저작권 조항 추출)

① 목적: OCR 텍스트에서 권리 귀속/양도·이용허락/2차적 저작물/범위·기간/귀속 등 핵심 조항을 정밀 위치와 함께 식별한다.

② 범위/대상: ocr_text.txt, 메타

③ 입력/출력 스키마

- ✓ 입력: ocr_text.txt, 메타
- ✓ 출력: 분류 결과(JSON)

```
{
  "contractId":"uuid",
  "clauses":[
    {"type":"OWNERSHIP","text":"저작권 일체는 발주기관에 귀속한다",
     "score":0.93,"page":3,"charStart":421,"charEnd":452,"templateId":"OWN_v2"},
    {"type":"LICENSE","text":"비독점 이용허락, 상업적 이용 금지",
     "score":0.88,"page":5,"charStart":112,"charEnd":140,"templateId":"LIC_v1"}
  ]
}
```

(그림 6) 입/출력 스키마(예시)

④ 처리 로직(요약)

패턴+NER 혼합 매칭 → 스팬/페이지 좌표 기록 → 신뢰도 산출

⑤ 인터페이스

- ✓ API: POST /contracts/{id}/clauses.

⑥ 예외/오류 처리

- ✓ 매칭 미달 → "검토 필요(조항 불충분)"로 분기

⑦ 로그/감사: 템플릿 버전, 매칭 점수, 스팬 오프셋

2.4 FR-04(계약 우선 판정)

① 목적: 계약 조항이 존재·충분한 경우 정책 엔진으로 권리 판정을 우선 적용한다.

② 입력/출력 스키마

- ✓ 입력: contract_evidence.json, 정책
- ✓ 출력: 분류 결과(JSON)

```
{
  "contractId":"uuid",
  "decision":{"basis":"OWNERSHIP","label":"own","confidence":0.95},
  "constraints":{"commercialUse":false,"territory":"KR","term":"perpetual"},
  "evidenceIds":["OWN_v2#p3#421-452"],
  "timestamp":"2025-08-24T04:12:00Z"
}
```

(그림 7) 입/출력 스키마(예시)

③ 계약 우선

OWNERSHIP/ASSIGN/ LICENSE 등 조항이 확인되면 AI 추정보다 우선한다.

④ 불충분/부재/저품질 시 검토 필요로 분기(2장의 임계치 정책 준용).

⑤ 인터페이스

- ✓ API: POST /contracts/{id}/policy/decide.

⑥ 예외/오류 처리

- ✓ 정책 충돌 시 "보류(HOLD)"로 표기하고 근거 남김.

⑦ 로그/감사: 우선 적용/분기 정책 일관성

2.5 FR-05(AI 기반 분류)

① 목적: 표준 속성(JSON)을 입력으로 KOGL/CC/PD 등 권리유형을 자동 분류

② 범위/대상: KOGL 제1~4유형, CC-BY/CC-BY-SA 등 공개 라이선스, 퍼블릭도메인(공/무권리) 포함

③ 입력/출력 스키마

- ✓ 입력: FR-01 출력(JSON) + 필요 시 파생 속성(키워드/벡터)
- ✓ 출력: 분류 결과(JSON)

```
{
  "fileId": "uuid",
    "predictedClass": "KOGL-1|KOGL-2|CC-BY|PD|...",
    "confidence": 0.0-1.0,
    "topK": [
      {"label": "KOGL-1", "score": 0.92},
      {"label": "CC-BY", "score": 0.05}
    ],
    "rationale": ["metadata:creator-null", "has-watermark:false", "keywords:..."],
    "modelVersion": "v1.3.2",
    "timestamp": "2025-07-04T04:08:00Z"
}
```

(그림 8) 입/출력 스키마(예시)

④ 처리 로직(요약)

- ✓ 사전검증(필수 속성 확인)→전처리/정규화→모델 추론→신뢰도 규칙 적용→결과/근거 저장

⑤ 인터페이스

- ✓ API: POST /classify (단건/배치), GET /classify/{fileId}
- ✓ 배치 스케줄: 신규/갱신 파일 큐 기반 비동기 추론

⑥ 예외/오류 처리

- ✓ 필수 속성 결핍: reviewRequired=true로 표기하고 보수적으로 낮은 신뢰 등급 부여
- ✓ 모델 불가용: 회로차단기 적용 후 재시도 큐로 이동

⑦ 로그/감사: 입력 해시, 모델버전, 예측/신뢰도, 규칙적용 내역, 소요시간 전부 기록

2.6 FR-06(초상권 여부 판단)

① 목적: 이미지/영상 프레임에서 얼굴 포함 여부를 보수적으로 판정해 인격권 리스크 최소화

② 범위/대상: 정면/측면/부분가림/군중(blurred) 포함, 저해상도·역광 등 난조건 대응. 영상은 대표 프레임 또는 일정 간격 샘플링 적용

③ 입력/출력 스키마

- ✓ 입력: 이미지 바이너리 또는 프레임 샘플, FR-01 속성
- ✓ 출력: 판정 결과(JSON)

```
{
  "fileId": "uuid",
    "facesDetected": 3,
    "maxConfidence": 0.87,
    "minConfidence": 0.41,
    "decision": "REVIEW_REQUIRED|NO_PORTRAIT",
    "thresholds": { "review": 0.60, "high": 0.85 },
    "notes": ["small-faces", "occlusion"],
    "timestamp": "2025-08-24T04:10:00Z"
}
```

(그림 9) 입/출력 스키마(예시)

④ 처리 로직(요약)

- ✓ 얼굴 검출/추정→신뢰도 집계→정책 적용→로고/워터마크와 교차정보 기록

⑤ 인터페이스

- ✓ API: POST /privacy/portrait/check
- ✓ UI: 썸네일 격자 + 검출 영역 오버레이(박스), 신뢰도/근거 표기, "검토 필요" 배지

⑥ 예외/오류 처리

- ✓ 해상도 과소: 자동 업스케일 시도, 실패 시 REVIEW_REQUIRED로 강등
- ✓ 강한 모자이크/필터: "분석 곤란"으로 로그 플래그 후 검토 대기

⑦ 로그/감사: 프레임 샘플링 규칙, 모델버전

2.7 FR-07(예외 처리)

① 목적: 계약 부재·불충분·저품질·포맷 미지원 등 예외 상황을 표준화해 안전하게 흐름을 유지한다.

② 입력/출력 스키마

- ✓ 입력: AI 결과(JSON), 사용자(검토자) 입력(정답/메모)
- ✓ 출력: 검토표/이력(JSON & 리포트)

```
{
  "fileId":"uuid",
  "exception":"NO_CONTRACT|LOW_OCR_QUALITY|
                NO_CLAUSE_MATCH|FORMAT_UNSUPPORTED|LEGACY_VENDOR",
    "action":"REVIEW|HOLD|REJECT",
    "reason":"missing purchase order number",
    "timestamp":"2025-08-24T04:20:00Z"
}
```

(그림 10) 입/출력 스키마(예시)

③ 처리 로직(요약)

✓ 예외 분류 → 대기 큐 배정 → 알림 발송 → 관리자 조치 기록

④ 인터페이스

✓ API: POST /exceptions, GET /exceptions?fileId=

⑤ 로그/감사: 각 항목의 전/후 상태, 변경자, 사유 등 저장

2.8 FR-08(자체 제작)

① 목적: 기관 자체 제작물에 대해 계약서 없이도 등록을 허용하고, 정책에 따른 기본 KOGL 유형을 제안한다

② 범위/대상: 각 기관별 자체 제작된 저작물

③ 입력/출력 스키마

✓ 입력: 플래그·메타(부서, 작성자, 생성일) → 정책 라벨·감사 로그.

✓ 출력: 검토표/이력(JSON & 리포트)

```
  {
    "fileId":"uuid",
    "isInstitutionMade":true,
    "dept":"문화홍보과",
    "creator":"홍길동",
    "policyLabel":"KOGL-1"
}
```

(그림 11) 입/출력 스키마(예시)

④ 업무 규칙

✓ 자체 제작 플래그가 명확하면 계약 절차 생략. 필수 메타 누락 시 예외 처리로 분기

⑤ 로그/감사

✓ API 호출·결정·임계치 변경은 저장

제4장 활용 방안

1. 활용 시나리오

본 장은 시스템의 실제 사용 맥락을 정의하고, 각 단계(입력→속성 추출→AI 분류→검증·연계→결과 제공)가 운영 현장에서 어떻게 활용하는지 기술한다. 대상 시나리오는 이미지, 영상/오디오, 어문(텍스트) 으로 구분한다.

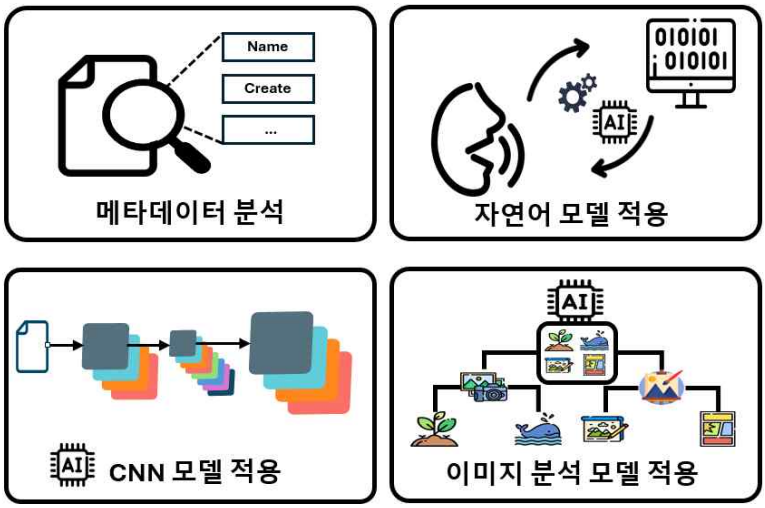

(그림 12) 활용 방안

- ✓ 이미지 저작물
- ✓ 어문(텍스트) 저작물
- ✓ 오디오 저작물
- ✓ 영상 저작물

2. 이미지 저작물 등록

본 시나리오는 이미지 저작물을 등록하는 순간부터 권리유형을 자동으로 판정하고, 초상권 리스크를 보수적으로 식별하며, 중복·유사 여부를 확인한 뒤 관리자가 최종 확정하고 기관 시스템으로 연계하기까지의 전 과정을 다룬다.

대상 포맷은 jpg/jpeg, png, webp, tiff, bmp를 기본으로 지원한다. 단일 파일과 다중 파일 업로드를 모두 처리하고, 수요기관 플랫폼으로부터의 배치 연계 또한 협의를 통해 구성한다.

2.1 전제조건 및 임계치

시스템은 안정적 분석을 위해 최소 해상도 512×512px, 파일 크기 100MB 이하를 권장 기준으로 둔다. 초상권 판단은 검출 신뢰도 0.60 이상일 때 "검토 필요"로 분류하고, 0.85 이상일 때 고신뢰 신호로 취급한다. 중복·유사도 판단은 지각 해시와 임베딩 유사도를 결합해 0.90 이상이면 유사 후보로 표기한다. 모든 업로드는 TLS 구간 보호와 토큰 인증을 거치며, 업로더·검토자·관리자 권한을 RBAC로 구분한다.

- ✓ 파일 크기: ≤ 100MB
- ✓ 해상도 ≥ 512×512px(최소 분석 해상도)
- ✓ 얼굴 검출 신뢰도: 임계치: reviewThreshold = 0.60, highConfidence = 0.85
- ✓ 중복·유사도 임계치: nearDuplicate ≥ 0.90(지각 해시+특징벡터 혼합 스코어)
- ✓ 악성코드/무결성: AV 엔진 스캔(정책), SHA-256 해시 저장

2.2 처리 절차

등록 즉시 권리유형을 추정하고, 초상권 리스크 등을 보수적으로 플래그한다.

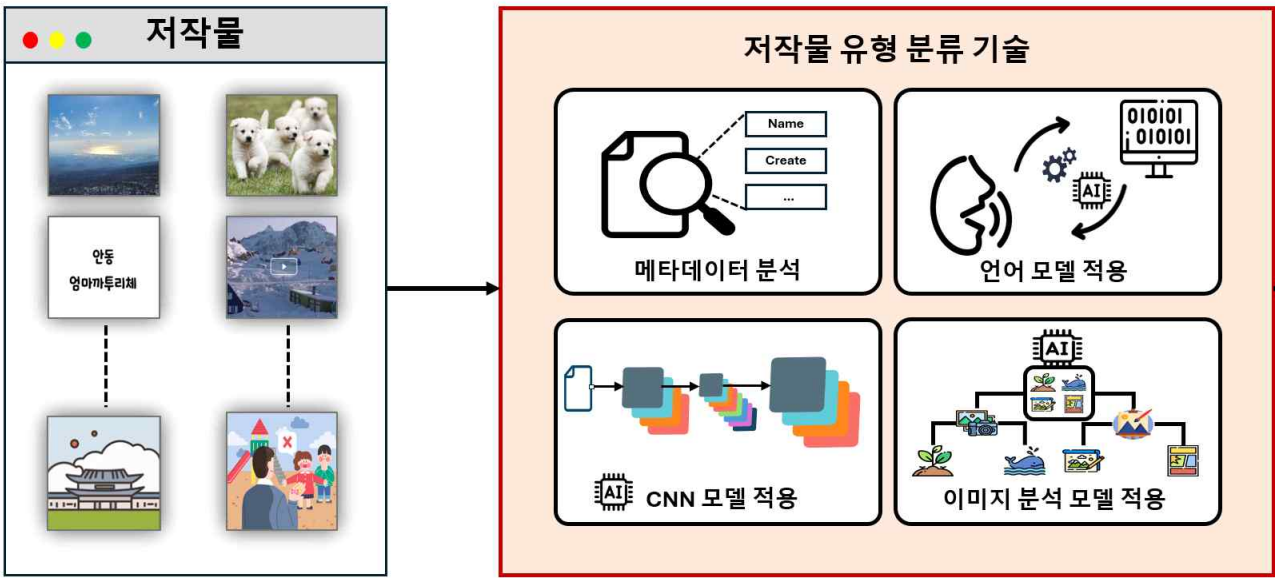

(그림 13) 이미지 시나리오

- ✓ 저작물 등록: 사용자가 이미지(단일 또는 다중) 업로드
- ✓ 시스템이 무결성·바이러스 검사를 수행하고, EXIF·크기·포맷 등 기본 속성 추출
- ✓ 얼굴·로고·워터마크를 탐지하고, 키포인트와 신뢰도를 속성 정보 등록
- ✓ AI 분류 엔진이 KOGL/CC/PD 중 최상위 라벨과 신뢰도 산출

- ✓ 얼굴 신뢰도 ≥ 임계치이면 "검토 필요(초상권)" 표시
- ✓ 관리자 대시보드가 자동 생성된 리포트와 썸네일/검출박스를 표시하고, 관리자는 승인/반려/수정 라벨 결정
- ✓ 추정 결과를 전달

2.3 산출물

이미지 저작물 등록·분석 결과는 재현 가능성과 기관 연계를 보장하기 위해 표준화된 산출물로 저장한다. 모든 산출물은 공통적으로 fileId, schemaVersion, timestamp, producer(생성 모듈/버전) 정보를 포함하며, 전송·보관 시 암호화를 적용한다. 핵심 산출물은 다음과 같다.

- ✓ classification.json
- ✓ portrait.json

2.3.1 classification.json

권리유형 분류의 최종 판단을 기록한다. 예측 라벨(예: KOGL-1, CC-BY, PD)과 신뢰도, 필요 시 상위 후보(Top-K)를 포함하고, 판단에 사용된 근거 키(메타데이터 단서, 워터마크 검출 여부, 키워드 등)를 함께 남긴다. 모델 버전과 생성 시각을 명시한다. 운영 단계에서는 본 파일을 기준으로 라벨 변경 이력과 모델 교체 전후의 성능 차이를 비교한다.

2.3.2 portrait.json

초상권 관련 판단을 이미지 단위로 정리한다. 얼굴 검출 개수, 최종 결정값(예: REVIEW_REQUIRED/NO_PORTRAIT), 적용 임계치(review, high)를 포함한다. 검출 박스 좌표와 썸네일 참조를 기록해 시각적 근거와 직접 연결하며, 역광·부분가림·저해상도와 같은 분석 불확실 요인을 주석으로 남긴다. 개인정보 보호를 위해 식별(인식) 값이나 얼굴 임베딩은 저장하지 않고, 존재 여부와 검토 필요 여부만을 보존한다.

3. 어문(텍스트) 저작물 등록

본 시나리오는 어문 저작물을 등록하는 순간부터 권리유형을 자동 판정하고, 라이선스 문구/근거를 식별하며, 중복·유사 여부를 확인한 뒤 관리자가 최종 확정하고 기관 시스템으로 연계하기까지의 전 과정을 다룬다. 대상 포맷은 pdf, docx, hwp, txt를 기본으로 지원한다. 단일·다중 업로드를 모두 처리하고, 수요기관 플랫폼의 배치 연계는 협의에 따라 구성한다.

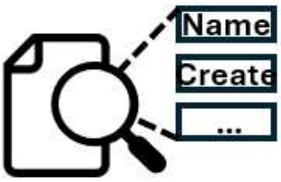

메타데이터 분석

유사 저작물 비교

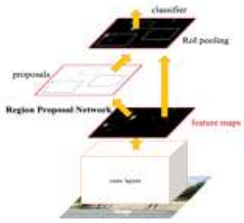

객체 탐지

(그림 14) 데이터 처리

3.1 전제조건 및 임계치

시스템은 안정적 분석을 위해 텍스트 추출 가능 여부를 우선 확인한다. 스캔 PDF는 OCR로 전환하고, 언어 감지를 통해 템플릿 매칭을 선택한다. 중복·유사도 평가는 문장 셰닐(Shingle) 기반 MinHash/Jaccard로 수행한다.

모든 업로드는 TLS 보호와 토큰 인증을 거치며 RBAC로 권한을 구분한다.

- ✓ 파일 크기: ≤ 100MB
- ✓ 텍스트 추출 실패 시 OCR 전환(해상도 200DPI 이상 권장)
- ✓ 라이선스 문구 매칭 신뢰도 임계치: licenseMatch ≥ 0.80(템플릿·규칙 혼합)
- ✓ 중복·유사도 임계치: textNearDuplicate ≥ 0.90(MinHash/Jaccard)
- ✓ 악성코드/무결성: AV 스캔, SHA-256 해시 저장

3.2 처리 절차

등록 즉시 권리유형을 추정한다.

- ✓ 저작물 등록: 사용자가 문서(단일/다중) 업로드
- ✓ 시스템이 무결성·바이러스 검사를 수행하고, 내장 텍스트/메타데이터를 추출(OCR 포함)
- ✓ 라이선스·저작권·출처 관련 표준 문구 템플릿과 매칭하고 근거 스팬(문장/페이지)을 식별
- ✓ 키워드·개체(NER)·언어 정보를 속성 정보로 등록
- ✓ AI 분류 엔진이 KOGL/CC/PD 중 최상위 라벨과 신뢰도를 산출
- ✓ 텍스트 유사도 조회로 중복 후보를 제시하고, 근거 비교 링크를 제공
- ✓ 확정 결과를 기관 플랫폼으로 전달

3.3 산출물

본 절차는 어문(텍스트) 저작물의 분석 결과를 기관 연계에 적합한 형태로 보존한다. 모든 산출물은 공통적으로 fileId, schemaVersion, timestamp, producer(생성 모듈/버전)를 포함하며, 전송·보관 시 암호화를 적용한다. 산출물 간에는 참조 키(예: page, charStart, charEnd, evidenceId)로 상호 연결하여 대시보드, 보고서, 재학습 파이프라인에서 일관되게 활용한다.

- ✓ classification.json(라벨·신뢰도·근거 키)
- ✓ evidence.json(라이선스 문구 하이라이트 위치/페이지/문장)
- ✓ dedup.json(유사 문서 후보 및 스코어)
- ✓ OCR 결과(ocr_text.txt) – 필요 시

3.3.1 classification.json

권리유형 분류의 최종 판단을 기록한다. 예측 라벨(예: KOGL-1, CC-BY, PD)과 판단에 사용된 근거 키를 배열로 제공한다. 메타데이터 단서(제작자/출처/배포처), 라이선스 문구 매칭 결과의 식별자(evidenceId), 문서 특성(언어, 길이, 키워드 등)을 모델 버전 정보를 함께 남긴다. 이 파일은 기관 웹훅의 핵심 페이로드로 사용되고, 모델 교체 전후 성능·결정 차이를 비교하는 기준이 된다.

3.3.2 evidence.json

라이선스/저작권/출처 관련 문구 매칭 결과를 정밀 위치 정보와 함께 저장한다. 각 항목에는 고유 evidenceId, 매칭 신뢰도, 페이지 번호, 문장·문단 단위의 문자 범위(charStart, charEnd), 하이라이트 텍스트 스냅샷, 규칙/템플릿 식별자 등이 포함된다. 개인정보나 민감 표현이 포함된 경우 정책에 따라 마스킹 태그를 부여하고, 해당 상태가 리포트/대시보드에도 일관되게 반영되도록 표시한다.

3.3.3 ocr_text.txt(옵션)

문서가 스캔본이거나 내장 텍스트가 없는 경우에만 생성한다. 페이지 순서대로 전사 텍스트를 수록하고, 페이지 헤더에는 페이지 번호, 엔진/버전, 언어 감지 결과 등 메타를 기록한다. 가능하면 문단/줄 단위 구분자를 유지하여 evidence.json의 위치 정보와 1:1 매핑되도록 하며, 품질이 낮은 영역(낮은 신뢰도, 왜곡/블러)은 주석으로 표기한다. 개인정보 마스킹 정책이 적용된 경우 마스킹된 상태로 저장하고 원문은 보안 영역에만 보관한다.

4. 영상 저작물 등록

본 시나리오는 영상 저작물을 등록한 뒤, 오디오/자막 분석과 프레임 기반 시각 분석을 결합해 권리유형을 판정하고, 초상권 리스크를 보수적으로 식별하며, 중복·유사 여부를 확인하고, 관리자가 확정한 결과를 기관 시스템으로 연계하기까지의 전 과정을 다룬다. 대상 포맷은 mp4, mov, mkv을 기본으로 지원한다.

OCR & NLP

Watermark & Logo

GAN 탐지

(그림 15) 데이터 처리

4.1 전제조건 및 임계치

분석 사전 단계에서 공통 프리셋으로 트랜스코딩하고, 프레임 샘플링과 음성인식(STT)을 수행한다. 초상권·유사도 임계치는 이미지/오디오 로직을 혼합해서 적용한다.

- ✓ 파일 크기: ≤ 2GB(실증 단계 권장), 길이 ≤ 60분(샘플 기준 조정 가능)
- ✓ 분석 프리셋: 720p, 2fps 샘플링, 오디오는 16kHz mono
- ✓ 얼굴 검출 신뢰도: reviewThreshold = 0.60, highConfidence = 0.85
- ✓ 중복·유사도 임계치: videoNearDuplicate ≥ 0.90(프레임 pHash+임베딩 혼합)
- ✓ 악성코드/무결성: AV 스캔, SHA-256 해시 저장

4.2 처리 절차

등록 즉시 권리유형을 추정하고, 초상권·중복 리스크를 플래그한다.

- ✓ 저작물 등록: 사용자가 영상 업로드 또는 경로 지정(S3/NAS)
- ✓ 시스템이 무결성 검사 후 분석 프리셋으로 트랜스코딩, 샷 경계와 키프레임 추출
- ✓ 키프레임에서 얼굴·로고·워터마크 탐지, 신뢰도와 위치를 속성 정보로 등록
- ✓ 오디오 트랙을 추출해 STT 수행, 언어/키워드/개체 정보를 생성
- ✓ AI 분류 엔진이 시각·언어 속성을 결합해 KOGL/CC/PD 라벨과 신뢰도를 산출
- ✓ 얼굴 신뢰도 또는 STT 신뢰도가 임계치 기준에 미달/초과하면 "검토 필요"로 표시
- ✓ 프레임·오디오 임베딩 기반 유사도 조회로 중복 후보 제시
- ✓ 관리자 대시보드가 타임라인, 키프레임 썸네일, 검출 오버레이, 자막 하이라이트를 표시하고 승인/반려/수정 결정
- ✓ 확정 결과를 기관 플랫폼으로 전달

4.3 산출물

본 절차는 영상 저작물에 대한 분석·검증 결과를 재현 가능하게 관리하기 위해 산출물을 표준화한다. 모든 산출물은 공통적으로 fileId, schemaVersion, modelVersion, timestamp를 포함하며, 전송·보관 시 암호화를 적용한다. 대시보드·웹훅·리포트의 기본 페이로드로 사용하며, 서로를 교차참조할 수 있도록 키(예: frameId, segmentId)를 공유한다.

- ✓ classification.json(라벨·신뢰도·멀티모달 근거)
- ✓ portrait.json(키프레임별 얼굴 검출 수·신뢰도·결정)
- ✓ transcript.json(STT 결과·언어·키워드)

4.3.1 classification.json

권리유형 분류의 최종 추정 결과를 기록한다. 예측 라벨(KOGL/CC/PD 등)과 신뢰도 등을 함께 저장한다. 멀티모달의 경우 키프레임 객체/워터마크 검출과 언어(STT 키워드/라이선스 문구 매칭) 신호를 구분해 나열하며, 적용된 전처리·규칙(임계치, 필터링) 메타를 포함한다. 이 파일은 기관 연계 시 핵심 결과로 전달되고, 운영 중 모델 교체 전후 비교의 기준으로 활용한다.

4.3.2 portrait.json

초상권 관련 판단을 키프레임 단위로 정리한다. 각 키프레임의 얼굴 검출 개수, 최대/평균 신뢰도, 최종 결정(예: REVIEW_REQUIRED/NO_PORTRAIT), 적용 임계치(review, high)를 명시한다. 검출 박스 좌표와 프레임 타임스탬프를 포함해 시각적 근거와 직접 연결되며, 판단 불확실 사유(역광·부분가림·저해상도 등)를 주석으로 남겨 이후 재검토와 정책 조정에 활용한다.

4.3.3 transcript.json (STT 결과·언어·키워드)

영상의 오디오 트랙에 대한 음성인식 결과를 저장한다. 전체 전사 텍스트와 구간별 타임스탬프, 언어 판별, 키워드/개체(NER)을 포함한다. 전사 신뢰도가 임계치 미만인 구간은 검토 플래그로 표시하며, 라이선스·저작권 관련 문구 매칭 결과를 근거 키로 연결해 classification 근거와 상호 참조할 수 있게 한다. 개인정보가 포함된 경우 정책에 따라 마스킹 태그를 부여한다.

5. 오디오 저작물 등록

본 시나리오는 오디오 저작물을 등록한 뒤, 음성인식(STT)과 오디오 특징 분석을 바탕으로 권리유형을 판정하고, 중복·유사 여부를 확인하여 관리자가 확정하고 기관 시스템과 연계하기까지의 절차를 다룬다. 대상 포맷은 mp3, wav, aac를 기본으로 지원한다.

5.1 전제조건 및 임계치

분석은 음성 구간 검출(VAD)과 STT를 중심으로 수행한다. 음악·효과음 등 비음성 구간이 많은 파일에 대해서는 신뢰도를 별도 표기한다.

- ✓ 파일 크기: ≤ 500MB, 길이 ≤ 120분(실증 단계 권장)
- ✓ 샘플레이트: ≥ 16kHz, 모노/스테레오 모두 지원
- ✓ STT 평균 신뢰도 임계치: sttConfidence ≥ 0.75(미만 시 "검토 필요")
- ✓ 음악/저작권 음원 감지 신뢰도: musicLikelihood ≥ 0.80 시 경고 메모
- ✓ 중복·유사도 임계치: audioNearDuplicate ≥ 0.92(오디오 핑거프린트/Chromaprint 기반)
- ✓ 악성코드/무결성: AV 스캔, SHA-256 해시 저장

5.2 처리 절차

등록 즉시 권리유형을 추정하고, 텍스트 근거와 함께 결과를 제시한다.

- ✓ 저작물 등록: 사용자가 오디오 업로드 또는 경로 지정
- ✓ 시스템이 무결성 검사 후 포맷을 정규화하고 VAD로 음성 구간을 추출
- ✓ STT를 수행해 전사본을 생성하고, 언어/키워드/개체 정보를 파생
- ✓ 저작권 관련 단서(가사 인용·특정 문구)를 탐지해 근거 메모를 생성
- ✓ AI 분류 엔진이 텍스트·메타를 결합해 KOGL/CC/PD 라벨과 신뢰도를 산출
- ✓ STT 신뢰도가 임계치 미만이거나 의심 단서가 있는 경우 "검토 필요"로 표시
- ✓ 오디오 핑거프린트로 중복 후보를 조회하고, 참조 링크를 제공
- ✓ 관리자 대시보드가 전사 하이라이트와 경고 메모를 표시하고 승인/반려/수정 결정
- ✓ 확정 결과를 기관 플랫폼으로 전달

5.3 산출물

본 절차는 분석 결과와 근거를 재현 가능하게 남기고, 기관 연계·운영 감사·재학습에 활용하기 위해 표준화된 산출물을 생성한다. 산출물은 서로 보완적 관계를 이루며, 동일 fileId와 스키마 버전 정보를 공유해 추적성과 무결성을 보장한다.

- ✓ classification.json(라벨·신뢰도·근거)
- ✓ transcript.json(STT 결과·언어·키워드)
- ✓ audio_fingerprint.json(해시·유사 후보·스코어)

5.3.1 classification.json

시스템은 권리유형 분류 결과를 classification.json으로 기록한다. 이 산출물은 예측 라벨(예: KOGL-1, CC-BY, PD), 신뢰도, 판정에 사용된 근거 키(메타데이터 유무, 텍스트·객체 검출 신호 등)를 포함한다. 모델 버전과 생성 시각을 함께 저장하여 관리한다. 운영 단계에서는 이 파일을 통해 라벨 변경 이력과 모델 교체 전후의 성능 변화를 신속히 비교한다.

5.3.2 transcript.json

오디오/영상에 포함된 음성은 음성인식(STT) 결과로 transcript.json에 정리한다. 본 산출물은 전체 전사 텍스트와 문장·구간별 타임스탬프, 언어 식별 결과, 키워드·개체(NER) 정보를 기록한다. 개인정보 및 민감 표현은 규정에 따라 마스킹하거나 표시 태그를 부여해 2차 활용 시 오남용을 방지한다.

5.3.3 audio_fingerprint.json

오디오 유사도 판정을 위해 시스템은 표준화된 핑거프린트와 해시를 audio_fingerprint.json에 저장한다. 이 산출물은 알고리즘(예: Chromaprint), 샘플레이트·채널 등 정규화 매개변수, 계산된 해시값, 1차 매칭 점수와 기준 임계치를 포함한다. 동일성/근접성 판단의 기초 자료로 쓰이며, 재처리 시 동일 입력에서 동일 결과를 보장하는지 무결성을 검증하는 기준이 된다. 충돌 가능성이나 저품질 구간이 감지되면 주석 필드로 사유를 남겨 후속 검토를 지원한다.

6. 시나리오 C: 계약서 기반

본 시나리오는 계약서 조항을 근거로 권리유형을 우선 판정하고, 근거가 부족하거나 판독이 곤란한 경우 검토 필요로 분기한 뒤 확정·연계를 완료하는 전 과정을 다룬다. AI 자동 추정은 보조 근거로 병행한다.

6.1 전제조건 및 임계치

- ✓ 입력 대상: 계약서 PDF/이미지(직인·간인 포함), 저작물 파일(선행 또는 후행 등록 모두 허용).
- ✓ 링킹 요건: 발주번호/업체명/납품물 식별자 중 1개 이상 제공.
- ✓ OCR 품질 기준 (2장의 정책 표 준용)
- ✓ 조항 매칭 임계치: licenseClauseMatch ≥ 0.85(템플릿+NER 혼합)
- ✓ 우선순위 규칙: 계약 조항 근거가 충분하면 정책 엔진 결과가 AI 추정보다 우선한다.
- ✓ 예외 플래그: 기관 자체 제작물은 계약 없이 진행한다(필수 메타 기록).

6.2 처리 절차

- ✓ 계약서 업로드/연계: 계약서 파일 수신 → 무결성 해시(SHA-256) 생성 → 발주번호/업체/납품물로 저작물과 링크.

- ✓ 전처리: de-skew/회전 교정, 노이즈 제거, 해상도 점검.
- ✓ OCR: 페이지별 전사 생성 및 품질 산출(신뢰도, WER).
- ✓ 조항 추출: 소유/양도·이용허락/2차적 저작물/범위·기간/귀속 등 핵심 조항 탐지(스팬·페이지 좌표 포함).
- ✓ 정책 엔진 판정(우선): 추출 조항을 정책에 매핑하여 own/assign/license 등 판정과 제약(상업·지역·기간)을 도출.
- ✓ AI 추정 병행: FR-05 분류를 수행해 보조 근거를 확보하고 불일치 여부를 체크한다.
- ✓ 검토 큐 분기: 조항 불충분 또는 AI·정책 불일치 시 검토 필요로 분기(사유 코드 포함).
- ✓ 확정 및 연계: 관리자가 근거를 검토하여 확정 → 기관 플랫폼에 결과·근거를 API/웹훅으로 전송.

6.3 결정 로직(우선순위)

6.3.1 계약 우선 적용:

- ✓ "저작권 일체는 발주기관에 귀속"/"업무상 저작물" 확인 → 기관 소유로 판정, KOGL 정책 적용.
- ✓ "비독점 이용허락, 상업적 이용 금지" 등 제한 명시 → 해당 제약을 반영해 라벨 후보를 제한한다.

6.3.2 불일치 처리

- ✓ 정책 판정과 AI 추정이 충돌하면 **검토 필요(HOLD)**로 표기하고 근거를 함께 표시한다.
- ✓ 자체 제작 예외: isInstitutionMade=true이면 계약 절차 생략, 기본 KOGL 유형을 제안하고 감사 로그에 기록한다.

6.4 예외/대체 흐름

- ✓ 계약서 부재: NO_CONTRACT → 검토 필요로 분기, AI 추정은 참고 자료로만 제공.
- ✓ 품질 저하/판독 불가: LOW_OCR_QUALITY 또는 NO_CLAUSE_MATCH → 검토 필요.
- ✓ 구업체(과거 계약 미존재): LEGACY_VENDOR → 검토 필요 + 기관 자체 제작 여부 확인.
- ✓ 보안·무결성 오류: 해시 불일치/변조 의심 → 처리 중단, 관리자 경보 및 포렌식 로그 보존.

6.5 산출물

- ✓ contract_evidence.json: 조항 유형, 매칭 점수, 페이지/문자 범위, 템플릿 ID, 원문 스니펫.
- ✓ ocr_text.txt: 페이지 순 전사 텍스트(신뢰도·WER·보정 각도 메타 포함).
- ✓ policy_decision.json: 정책 기반 판정(own/assign/license), 제약(상업·지역·기간), 타임스탬프.

제5장 성능 평가 및 검증 기준

1. 개요

본 장은 시스템의 권리유형 자동 분류 성능을 정밀도(Precision), 재현율(Recall), F1-Score를 중심으로 평가하고, 결과를 권리유형별 및 콘텐츠 유형별 정확도와 오류율로 세분화하여 보고한다. 평가는 KOGL-1~4, CC-BY, CC-BY-SA, 퍼블릭도메인 등과 이미지·영상·오디오·어문 등 매체 유형을 대상으로 하며, 결과는 운영 환경에서 수용 기준으로 확정한다.

2. 평가 지표 정의

재현율은 실제 정답 중 모델이 올바르게 찾아낸 비율을 의미한다. F1-Score는 정밀도와 재현율의 조화평균으로 불균형 데이터에서 균형 잡힌 성능을 표현한다. 보고는 각 권리유형에 대한 per-class P/R/F1을 기본으로 하고, 전체 성능은 모든 클래스를 동일 가중으로 평균한 Macro-F1을 사용한다.

필요 시 데이터 분포를 반영한 Micro-F1을 참고 지표로 병기한다. 초상권과 같이 이진 판정이 포함되는 과제도 동일한 정의를 적용한다.

2.1 정밀도(Precision)

정밀도는 모델이 "긍정(또는 특정 라벨)"이라고 예측한 것 중 실제로 맞은 비율을 의미한다. 잘못된 긍정을 줄이는 능력을 가늠한다.

- ✓ 정밀도(Precision) = TP / (TP + FP[1]) : 모델이 "맞다고 한 것" 중 실제로 맞은 비율

2.2 재현율(Recall)

재현율은 실제로 맞는 것 중에서 모델이 얼마나 놓치지 않고 찾아냈는지를 의미한다.

- ✓ 재현율(Recall) = TP / (TP + FN[2]) : 실제로 맞는 것 중 모델이 맞다고 찾아낸 비율

1) TP(True Positive, 참긍정), FP(False Positive, 거짓긍정)
2) TN(True Negative, 참부정), FN(False Negative, 거짓부정)

2.3 F1-Score

F1은 정밀도와 재현율의 조화 평균으로, 두 지표 간 균형을 본다. 데이터 불균형 상황에서도 비교적 공정하게 성능을 표현한다.

- ✓ F1-Score = 2 × (Precision × Recall) / (Precision + Recall) : 정밀도와 재현율의 조화 평균으로, 불균형 데이터에서 성능을 균형 있게 반영, 정밀도와 재현율 중 하나라도 낮으면 함께 낮아진다.

3. 데이터셋 및 정답지

데이터는 학습·검증·테스트로 분리하고, 동일 원본의 파생본이 서로 다른 분할에 섞이지 않도록 관리한다. 권리유형과 매체 유형, 해상도·길이, 언어·출처의 분포를 고려해 층화 표집을 수행하며, 정답 라벨은 두 명 이상의 독립 라벨러가 부여한 후 불일치 사례를 합의로 확정한다. 난이도가 높은 사례(초상권 의심, 워터마크 존재, 다국어 혼재, 저해상도·강필터 적용)는 별도 표지로 관리하여 세부 성능을 추가 점검한다. 테스트셋은 평가 시점에 고정하고, 버전 태깅과 변경 이력 관리를 통해 재현 가능성을 확보한다.

- ✓ 학습·검증·테스트를 70/15/15로 분리하, 동일 원본 파생본은 동일 분할에 묶어 누수 방지
- ✓ 정답 라벨은 2인 이상 교차 검수로 확정하고 불일치 건은 합의 조정

4. 평가 절차

모델 버전과 전처리 파이프라인, 임계치를 고정한 상태에서 테스트셋에 대해 단일 추론을 수행하고, 혼동행렬을 기반으로 per-class 정밀도·재현율·F1과 Macro-F1을 산출한다. 산출물은 매체 유형별로도 분리해 보고하여 매체 특성에 따른 성능 편차를 확인한다.

이후 오류 분석 단계에서 대표적인 혼동 쌍을 식별하고, 메타데이터 누락, 템플릿 문구 변형, 해상도 저하·부분가림 등 원인을 유형화해 개선 포인트를 도출한다.

- ✓ 임계치(예: 초상권 reviewThreshold=0.60)를 고정하고 테스트셋에 대해 1회 추론 수행
- ✓ 클래스별 혼동행렬을 생성하고, P/R/F1을 산출한 뒤 Macro-F1 집계
- ✓ 결를 콘텐츠 유형별로도 분리 산출하여 매체 특성에 따른 편차 확인
- ✓ 오류 분석을 위해 상위 혼동 쌍(예: KOGL-1↔KOGL-2)을 추출 및 원인 기술

5. 유형별 정확도 및 오류율 측정

권리유형별로 정확도와 오류율을 산출하되, 클래스 불균형의 영향을 받는 단순 정확도에만 의존하지 않고 per-class F1을 핵심 판단 근거로 사용한다. 콘텐츠 유형별로도 동일 지표를 산출하여 이미지·영상·오디오·어문 간 난이도 차이를 파악하고, 영상과 오디오의 경우 전사(STT) 신뢰도나 키프레임 품질과 같은 보조 지표를 함께 기록한다. 과대판정과 누락을 구분해 원인을 추적하고, 필요 시 임계치 조정이나 전처리 보강 계획을 수립한다.

6. 보고 형식

보고서는 각 권리유형에 대해 정밀도·재현율·F1과 함께 정확도, 오류율, 평가 표본 수를 서술형으로 제시한다. 전체 요약에는 Macro-F1과 Micro-F1, 전체 정확도와 전체 오류율을 포함한다. 부록에는 권리유형별 혼동행렬과 매체별 성능 요약표, 대표 오류 사례를 첨부하여 성능 해석을 지원한다. 수요기관 제출본에는 평가 환경과 모델 버전, 파이프라인 설정을 명시해 재현성을 보장한다.

7. 수용 기준

최종 합격 기준은 Macro-F1이 목표치를 충족하고, 모든 권리유형에서 per-class F1이 최저 기준 이상을 동시에 만족하는 것으로 정의한다. 매체 유형별 정확도와 오류율 역시 사전 합의된 범위를 충족해야 하며, 하나라도 미달하는 항목이 발생할 경우 데이터 보강, 전처리 개선, 임계치 재설정, 재학습 계획을 포함한 개선안을 마련하고 재평가 일정을 확정한다.

제6장 결론

본 기능요구사항 정의서는 공유저작물 권리유형 자동 추정을 위한 시스템 요구를 확정한다. 시스템은 업로드 즉시 속성 자동 추출 → AI 권리유형 분류 → 보수적 초상권 표지 → 중복·유사 검증의 흐름으로 동작하며, 결과를 표준 JSON 스키마와 REST API/웹훅으로 제공한다.

UI를 통해 자동 판정 결과와 근거를 확인하고 검토·승인(휴먼 인 더 루프)을 수행한다. 이 구성이 공공누리·공유마당 등과의 연계 가능성을 확보하고, 향후 상용화를 위한 기반을 마련한다.

1) 개발 범위

- ✓ 단건/배치 업로드, 속성 자동 추출(텍스트/OCR·이미지·오디오/영상), 권리유형 자동 추정, 초상권 보수 플래그
- ✓ 검토·승인·변경이력, 표준 산출물(classification.json, portrait.json, transcript.json, keyframes)
- ✓ 연계 인터페이스(REST API, 웹훅), 보안·운영 기본요건(RBAC, TLS, 감사 로그)

2) 수용 기준

- ✓ 분류 성능: Macro-F1 ≥ 0.90, 클래스별 F1 ≥ 0.85
- ✓ 초상권: 얼굴 포함 샘플 Recall ≥ 0.95(@reviewThreshold=0.60), 운영 리뷰율 관리
- ✓ 처리/가용성: 업로드→리포트 95p ≤ 6초(5MB 기준), 월가용성 ≥ 99.5%

3) 운영 및 변경 원칙

- ✓ 임계치·규칙은 운영 정책으로 조정하며, 변경 시 재검증한다.
- ✓ 모든 연계·검토·변경은 감사 가능하도록 기록한다.

위 요구를 충족하는 시스템을 구현·검증함으로써, 본 과제는 권리유형 자동 추정과 근거 제시를 표준화하고 기관 연계와 실사용 검증이 가능한 상태를 확보한다. 이는 이후 단계의 상용화 추진을 위한 실질적 기반으로 기능한다.